

GUIDE D'INSTALLATION

APACHE HADOOP

Installation complète sur Linux (Ubuntu/CentOS)

Modes : Standalone • Pseudo-distribué • Cluster

Version Hadoop 3.x | Février 2026

Table des Matières

1. Introduction et Prérequis
2. Installation de Java (JDK)
3. Création de l'utilisateur Hadoop
4. Configuration SSH sans mot de passe
5. Téléchargement et Installation de Hadoop
6. Configuration des Variables d'Environnement
7. Configuration des Fichiers Hadoop
 - 7.1 core-site.xml
 - 7.2 hdfs-site.xml
 - 7.3 mapred-site.xml
 - 7.4 yarn-site.xml
8. Formatage du NameNode
9. Démarrage des Services Hadoop
10. Vérification de l'Installation
11. Test avec un Job MapReduce
12. Configuration Multi-Nœuds (Cluster)
13. Commandes Utiles
14. Dépannage et Problèmes Courants

1. Introduction et Prérequis

Apache Hadoop est un framework open-source pour le stockage et le traitement distribué de grandes quantités de données. Ce guide couvre l'installation complète de Hadoop 3.x sur un système Linux.

Modes d'Installation

Mode	Description	Usage
Standalone	Mode par défaut, un seul processus Java	Développement, tests
Pseudo-distribué	Simule un cluster sur une seule machine	Apprentissage, développement
Distribué (Cluster)	Plusieurs machines en réseau	Production

Prérequis Système

Composant	Minimum	Recommandé
Système d'exploitation	Ubuntu 18.04+ / CentOS 7+	Ubuntu 22.04 LTS
RAM	4 Go	8 Go ou plus
Espace disque	10 Go	50 Go ou plus
Java	JDK 8	JDK 11 (OpenJDK)
SSH	OpenSSH Server	OpenSSH Server
Réseau	Connexion stable	IP statique

2. Installation de Java (JDK)

Hadoop nécessite Java pour fonctionner. Nous allons installer OpenJDK 11.

Étape 2.1 : Mise à jour du système

```
# Mise à jour des paquets  
sudo apt update && sudo apt upgrade -y
```

Étape 2.2 : Installation de OpenJDK 11

Pour Ubuntu/Debian :

```
sudo apt install openjdk-11-jdk -y
```

Pour CentOS/RHEL :

```
sudo yum install java-11-openjdk java-11-openjdk-devel -y
```

Étape 2.3 : Vérification de l'installation

```
java -version  
javac -version
```

Résultat attendu :

```
openjdk version "11.0.x" 2024-xx-xx  
OpenJDK Runtime Environment (build 11.0.x+x-Ubuntu-xxx)  
OpenJDK 64-Bit Server VM (build 11.0.x+x-Ubuntu-xxx, mixed mode)
```

Étape 2.4 : Configuration de JAVA_HOME

Trouvez le chemin de Java :

```
sudo update-alternatives --config java  
# ou  
readlink -f $(which java)
```

Le chemin sera généralement : /usr/lib/jvm/java-11-openjdk-amd64

3. Création de l'Utilisateur Hadoop

Il est recommandé de créer un utilisateur dédié pour exécuter Hadoop, pour des raisons de sécurité et de gestion.

Étape 3.1 : Création de l'utilisateur

```
# Créer un utilisateur hadoop
sudo adduser hadoop

# Ajouter l'utilisateur au groupe sudo (optionnel)
sudo usermod -aG sudo hadoop
```

Étape 3.2 : Connexion en tant qu'utilisateur hadoop

```
# Se connecter en tant que hadoop
su - hadoop

# Vérifier l'utilisateur actuel
whoami
```

❑ Important : Toutes les étapes suivantes doivent être exécutées en tant qu'utilisateur hadoop.

4. Configuration SSH sans Mot de Passe

Hadoop utilise SSH pour communiquer entre les nœuds. Nous devons configurer l'authentification par clé pour éviter les demandes de mot de passe.

Étape 4.1 : Installation de SSH (si nécessaire)

```
sudo apt install openssh-server openssh-client -y

# Démarrer le service SSH
sudo systemctl start ssh
sudo systemctl enable ssh
```

Étape 4.2 : Génération de la clé SSH

```
# Générer une paire de clés RSA (appuyez sur Entrée pour accepter les valeurs par défaut)
ssh-keygen -t rsa -P "" -f ~/.ssh/id_rsa
```

Étape 4.3 : Autorisation de la clé

```
# Ajouter la clé publique aux clés autorisées
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys

# Définir les permissions correctes
chmod 600 ~/.ssh/authorized_keys
chmod 700 ~/.ssh
```

Étape 4.4 : Test de la connexion SSH

```
# Tester la connexion SSH localhost
ssh localhost

# Si c'est la première connexion, tapez 'yes' pour accepter
# Vous devriez vous connecter sans mot de passe

# Pour sortir
exit
```

✓ Si vous pouvez vous connecter sans mot de passe, SSH est correctement configuré.

5. Téléchargement et Installation de Hadoop

Étape 5.1 : Téléchargement de Hadoop

Téléchargez la dernière version stable depuis le site officiel Apache :

```
# Aller dans le répertoire home
cd ~

# Télécharger Hadoop 3.3.6 (vérifiez la dernière version sur hadoop.apache.org)
wget https://dlcdn.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
```

Étape 5.2 : Extraction de l'archive

```
# Extraire l'archive
tar -xzf hadoop-3.3.6.tar.gz

# Renommer le dossier pour simplifier
mv hadoop-3.3.6 hadoop

# Supprimer l'archive (optionnel)
rm hadoop-3.3.6.tar.gz
```

Étape 5.3 : Vérification de la structure

```
# Vérifier la structure du dossier
ls -la ~/hadoop/

# Résultat attendu :
# bin/      - Commandes Hadoop
# etc/      - Fichiers de configuration
# lib/      - Bibliothèques Java
# sbin/     - Scripts de démarrage/arrêt
# share/    - Documentation et exemples
```

6. Configuration des Variables d'Environnement

Configurez les variables d'environnement pour que le système puisse trouver Hadoop et Java.

Étape 6.1 : Édition du fichier .bashrc

```
# Ouvrir le fichier .bashrc
nano ~/.bashrc
```

Ajoutez les lignes suivantes à la fin du fichier :

```
# Java Environment
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export PATH=$PATH:$JAVA_HOME/bin

# Hadoop Environment
export HADOOP_HOME=/home/hadoop/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export HADOOP_YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

Étape 6.2 : Application des changements

```
# Recharger le fichier .bashrc
source ~/.bashrc

# Vérifier les variables
echo $HADOOP_HOME
echo $JAVA_HOME
```

Étape 6.3 : Configuration de JAVA_HOME dans Hadoop

```
# Éditer le fichier hadoop-env.sh
nano $HADOOP_HOME/etc/hadoop/hadoop-env.sh

# Trouver la ligne JAVA_HOME et la modifier :
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

Étape 6.4 : Vérification de l'installation Hadoop

```
# Vérifier la version de Hadoop
hadoop version
```

Résultat attendu :

```
Hadoop 3.3.6
Source code repository https://github.com/apache/hadoop.git
Compiled by ubuntu on 2023-xx-xx
Compiled with protoc 3.7.1
From source with checksum xxxxx
```


7. Configuration des Fichiers Hadoop

Les fichiers de configuration se trouvent dans \$HADOOP_HOME/etc/hadoop/. Nous allons configurer les 4 fichiers principaux pour le mode pseudo-distribué.

7.1 Configuration de core-site.xml

Ce fichier contient les paramètres de configuration du système de fichiers Hadoop.

```
nano $HADOOP_HOME/etc/hadoop/core-site.xml
```

Remplacez le contenu par :

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://localhost:9000</value>
    <description>URI du système de fichiers par défaut</description>
  </property>
  <property>
    <name>hadoop.tmp.dir</name>
    <value>/home/hadoop/hadoopdata/tmp</value>
    <description>Répertoire temporaire Hadoop</description>
  </property>
</configuration>
```

7.2 Configuration de hdfs-site.xml

Ce fichier configure HDFS (Hadoop Distributed File System).

```
nano $HADOOP_HOME/etc/hadoop/hdfs-site.xml
```

Contenu :

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
    <description>Facteur de réplication (1 pour pseudo-distribué)</description>
  </property>
  <property>
    <name>dfs.namenode.name.dir</name>
    <value>file:///home/hadoop/hadoopdata/namenode</value>
    <description>Répertoire du NameNode</description>
  </property>
  <property>
    <name>dfs.datanode.data.dir</name>
    <value>file:///home/hadoop/hadoopdata/datanode</value>
    <description>Répertoire du DataNode</description>
  </property>
</configuration>
```

7.3 Configuration de mapred-site.xml

Ce fichier configure le framework MapReduce.

```
nano $HADOOP_HOME/etc/hadoop/mapred-site.xml
```

Contenu :

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
  <property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
    <description>Framework d'exécution MapReduce</description>
  </property>
  <property>
    <name>mapreduce.application.classpath</name>

<value>$HADOOP_MAPRED_HOME/share/hadoop/mapreduce/*:$HADOOP_MAPRED_HOME/share/hadoop/mapred
uce/lib/*</value>
  </property>
</configuration>
```

7.4 Configuration de yarn-site.xml

Ce fichier configure YARN (Yet Another Resource Negotiator).

```
nano $HADOOP_HOME/etc/hadoop/yarn-site.xml
```

Contenu :

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>
  <property>
    <name>yarn.nodemanager.env-whitelist</name>

<value>JAVA_HOME,HADOOP_COMMON_HOME,HADOOP_HDFS_HOME,HADOOP_CONF_DIR,CLASSPATH_PREPEND_DIST
CACHE,HADOOP_YARN_HOME,HADOOP_HOME,PATH,LANG,TZ,HADOOP_MAPRED_HOME</value>
  </property>
</configuration>
```

7.5 Création des répertoires de données

```
# Créer les répertoires pour les données Hadoop
mkdir -p ~/hadoopdata/namenode
mkdir -p ~/hadoopdata/datanode
mkdir -p ~/hadoopdata/tmp
```

8. Formatage du NameNode

Avant le premier démarrage, vous devez formater le NameNode. Cette opération initialise le système de fichiers HDFS.

□ ATTENTION : Le formatage efface toutes les données HDFS ! Ne l'exécutez qu'une seule fois lors de l'installation initiale.

Commande de formatage

```
# Formater le NameNode  
hdfs namenode -format
```

Vous verrez de nombreuses lignes de log. Cherchez le message de succès :

```
INFO common.Storage: Storage directory /home/hadoop/hadoopdata/namenode has been  
successfully formatted.
```

9. Démarrage des Services Hadoop

Étape 9.1 : Démarrage de HDFS

```
# Démarrer HDFS (NameNode et DataNode)
start-dfs.sh
```

Étape 9.2 : Démarrage de YARN

```
# Démarrer YARN (ResourceManager et NodeManager)
start-yarn.sh
```

Étape 9.3 : Alternative - Démarrer tous les services

```
# Démarrer tous les services Hadoop en une commande
start-all.sh
```

Étape 9.4 : Vérification des processus

```
# Vérifier les processus Java en cours
jps
```

Résultat attendu (6 processus) :

```
12345 NameNode
12346 DataNode
12347 SecondaryNameNode
12348 ResourceManager
12349 NodeManager
12350 Jps
```

10. Vérification de l'Installation

10.1 Interfaces Web Hadoop

Hadoop fournit des interfaces web pour surveiller les services :

Interface	URL	Description
NameNode	http://localhost:9870	État HDFS, espace disque, fichiers
ResourceManager	http://localhost:8088	Jobs YARN, applications, ressources
DataNode	http://localhost:9864	État du DataNode local
Secondary NameNode	http://localhost:9868	Checkpoints du NameNode

10.2 Test des commandes HDFS

```
# Créer un répertoire dans HDFS
hdfs dfs -mkdir /user
hdfs dfs -mkdir /user/hadoop

# Lister le contenu
hdfs dfs -ls /

# Créer un fichier test
echo "Hello Hadoop!" > test.txt

# Copier le fichier vers HDFS
hdfs dfs -put test.txt /user/hadoop/

# Lire le fichier depuis HDFS
hdfs dfs -cat /user/hadoop/test.txt

# Vérifier l'état du système de fichiers
hdfs dfsadmin -report
```

11. Test avec un Job MapReduce

Exécutons l'exemple WordCount fourni avec Hadoop pour vérifier que MapReduce fonctionne correctement.

Étape 11.1 : Préparer les données d'entrée

```
# Créer un répertoire d'entrée dans HDFS
hdfs dfs -mkdir -p /user/hadoop/input

# Créer des fichiers de test
echo "Hello World Hello Hadoop" > file1.txt
echo "Hadoop is a framework for Big Data" > file2.txt
echo "Big Data processing with Hadoop" > file3.txt

# Copier les fichiers vers HDFS
hdfs dfs -put file1.txt file2.txt file3.txt /user/hadoop/input/

# Vérifier les fichiers
hdfs dfs -ls /user/hadoop/input/
```

Étape 11.2 : Exécuter le job WordCount

```
# Exécuter le job MapReduce WordCount
hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.jar
wordcount /user/hadoop/input /user/hadoop/output
```

Étape 11.3 : Vérifier les résultats

```
# Lister les fichiers de sortie
hdfs dfs -ls /user/hadoop/output/

# Afficher les résultats
hdfs dfs -cat /user/hadoop/output/part-r-00000
```

Résultat attendu (comptage des mots) :

```
Big      2
Data     2
Hadoop   3
Hello    2
World    1
a        1
for      1
framework      1
is        1
processing     1
with         1
```

✔ Si vous voyez le comptage des mots, votre installation Hadoop est fonctionnelle !

12. Configuration Multi-Nœuds (Cluster)

Pour un environnement de production, vous devez configurer Hadoop sur plusieurs machines. Voici les étapes supplémentaires.

12.1 Architecture du Cluster

Machine	IP (exemple)	Rôles
master	192.168.1.100	NameNode, ResourceManager, SecondaryNameNode
slave1	192.168.1.101	DataNode, NodeManager
slave2	192.168.1.102	DataNode, NodeManager
slave3	192.168.1.103	DataNode, NodeManager

12.2 Configuration du fichier /etc/hosts

Sur TOUTES les machines, éditez /etc/hosts :

```
# Ajouter les entrées suivantes sur chaque machine
192.168.1.100    master
192.168.1.101    slave1
192.168.1.102    slave2
192.168.1.103    slave3
```

12.3 Configuration SSH entre les nœuds

```
# Sur le master, copier la clé SSH vers tous les slaves
ssh-copy-id hadoop@slave1
ssh-copy-id hadoop@slave2
ssh-copy-id hadoop@slave3

# Tester les connexions
ssh slave1
ssh slave2
ssh slave3
```

12.4 Fichier workers

Sur le master, éditez le fichier workers :

```
nano $HADOOP_HOME/etc/hadoop/workers

# Contenu du fichier :
slave1
slave2
slave3
```

12.5 Modification de core-site.xml pour le cluster

```
<!-- Remplacer localhost par le nom du master -->
<property>
  <name>fs.defaultFS</name>
  <value>hdfs://master:9000</value>
</property>
```

12.6 Modification de hdfs-site.xml

```
<!-- Augmenter le facteur de réplication -->  
<property>  
  <name>dfs.replication</name>  
  <value>3</value>  
</property>
```


13. Commandes Utiles

13.1 Gestion des services

```
# Démarrer tous les services
start-all.sh

# Arrêter tous les services
stop-all.sh

# Démarrer/arrêter HDFS uniquement
start-dfs.sh
stop-dfs.sh

# Démarrer/arrêter YARN uniquement
start-yarn.sh
stop-yarn.sh

# Vérifier les processus
jps
```

13.2 Commandes HDFS

```
# Lister les fichiers
hdfs dfs -ls /chemin

# Créer un répertoire
hdfs dfs -mkdir /repertoire

# Copier un fichier local vers HDFS
hdfs dfs -put fichier_local /chemin/hdfs

# Copier un fichier HDFS vers local
hdfs dfs -get /chemin/hdfs fichier_local

# Afficher le contenu d'un fichier
hdfs dfs -cat /chemin/fichier

# Supprimer un fichier/répertoire
hdfs dfs -rm /chemin/fichier
hdfs dfs -rm -r /chemin/repertoire

# Vérifier l'espace disque
hdfs dfs -df -h

# Rapport du cluster
hdfs dfsadmin -report

# Mode sans échec
hdfs dfsadmin -safemode get
hdfs dfsadmin -safemode leave
```

13.3 Commandes YARN

```
# Lister les applications
yarn application -list
```

```
# Tuer une application
yarn application -kill <application_id>

# État des nœuds
yarn node -list

# Logs d'une application
yarn logs -applicationId <application_id>
```

14. Dépannage et Problèmes Courants

14.1 NameNode ne démarre pas

Symptôme : Le processus NameNode n'apparaît pas dans jps

Solutions :

```
# 1. Vérifier les logs
cat $HADOOP_HOME/logs/hadoop-*-namenode-*.log

# 2. Reformater le NameNode (ATTENTION: perte de données!)
stop-dfs.sh
rm -rf ~/hadoopdata/namenode/*
rm -rf ~/hadoopdata/datanode/*
hdfs namenode -format
start-dfs.sh
```

14.2 DataNode ne démarre pas

```
# Vérifier la version du cluster
# DataNode peut refuser de se connecter si les IDs ne correspondent pas

# Solution: supprimer les données du DataNode et redémarrer
rm -rf ~/hadoopdata/datanode/*
start-dfs.sh
```

14.3 Erreur SSH "Permission denied"

```
# Vérifier les permissions
chmod 700 ~/.ssh
chmod 600 ~/.ssh/authorized_keys
chmod 600 ~/.ssh/id_rsa
chmod 644 ~/.ssh/id_rsa.pub

# Régénérer les clés si nécessaire
ssh-keygen -t rsa -P "" -f ~/.ssh/id_rsa
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
```

14.4 HDFS en mode sans échec (Safe Mode)

```
# Vérifier le mode
hdfs dfsadmin -safemode get

# Sortir du mode sans échec
hdfs dfsadmin -safemode leave
```

14.5 Erreur "JAVA_HOME is not set"

```
# Vérifier JAVA_HOME
echo $JAVA_HOME

# Configurer dans hadoop-env.sh
nano $HADOOP_HOME/etc/hadoop/hadoop-env.sh

# Ajouter la ligne :
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

14.6 Emplacements des logs

```
# Logs Hadoop
$HADOOP_HOME/logs/

# Logs spécifiques
hadoop-*-namenode-*.log
hadoop-*-datanode-*.log
hadoop-*-resourcemanager-*.log
hadoop-*-nodemanager-*.log
```

— Fin du Guide d'Installation —